Средства анализа нагрузки на структуры хранения данных

Обучающийся: Потапов Д. Р.
Руководитель: Селезнев К. Е.

Введение

Потребность эффективно хранить и обрабатывать информацию

Огромное количество различных модулей хранения информации и их комбинаций

Необходимость анализа работы контейнеров для выбора оптимального

Примеры необходимости оптимального контейнера

- индекс базы данных (если структура индекса хорошо оптимизирована под поиск, то происходит сильное ускорение работы);
- системы с ограниченными ресурсами (если структуры данных оптимальны, то система работает быстро).

Постановка задачи

Разработать программное обеспечение, в котором должны быть реализованы:

1. Визуализация нагрузки на одном контейнере.
2. Визуализация сравнения нескольких контейнеров.
3. Алгоритм получения линейного классификатора для адаптивного выбора оптимального способа хранения данных в зависимости от нагрузки.

Модель нагрузки

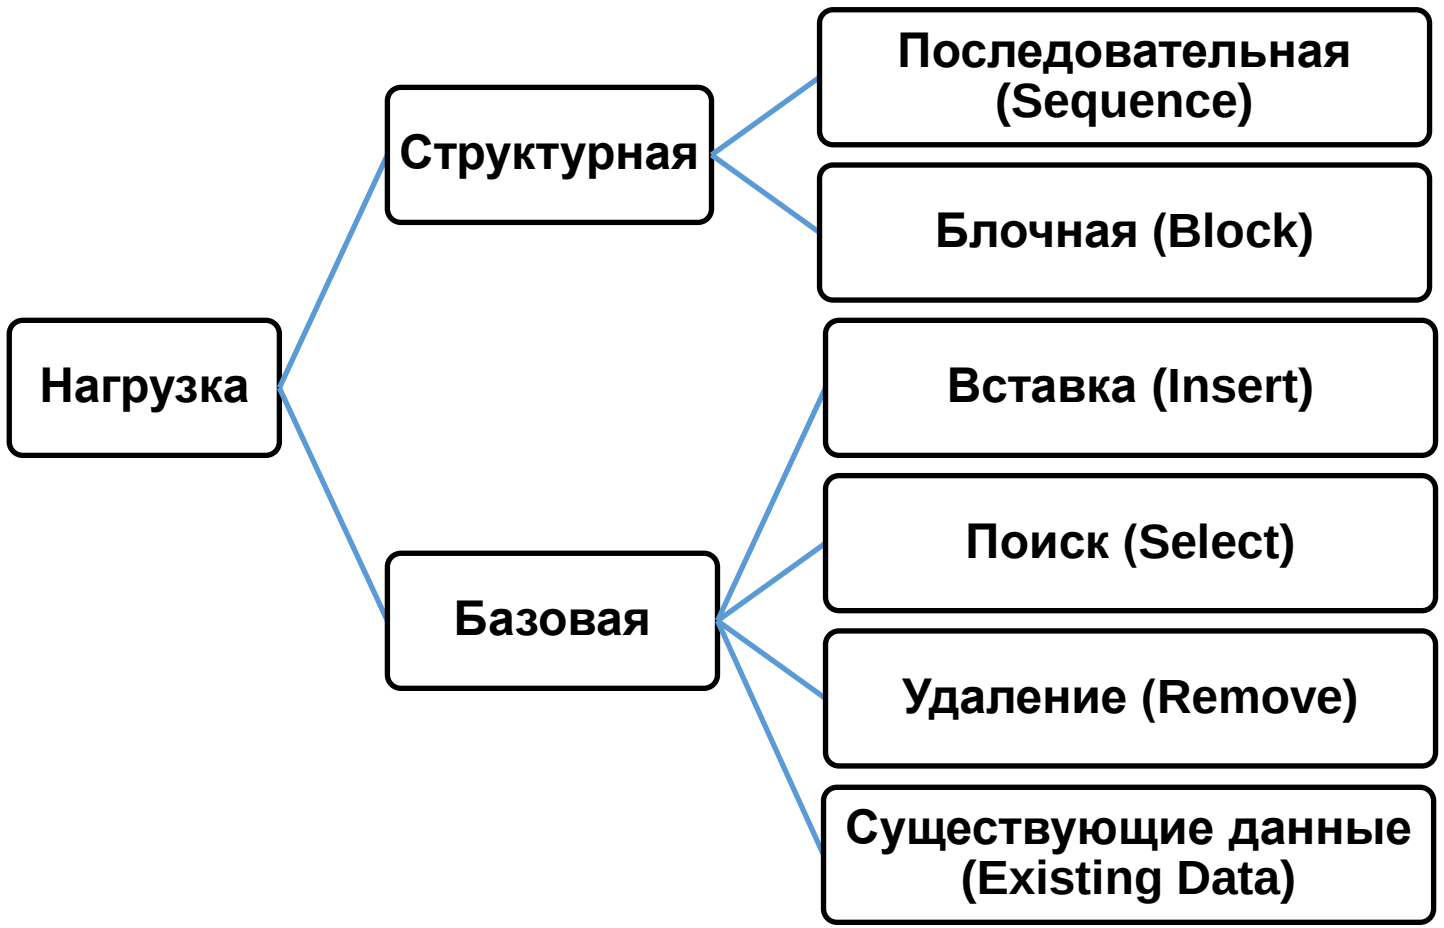

Методы индексации данных

Каждый метод индексации данных должен предоставлять базовый интерфейс для работы с контейнером. Такой интерфейс должен содержать три базовых операции:

1. Поиск (Select). Операция чтения данных из контейнера.
2. Вставка (Insert). Операция вставки данных.
3. Удаление (Remove). Операция удаления данных.

Способ оценки метода индексации данных

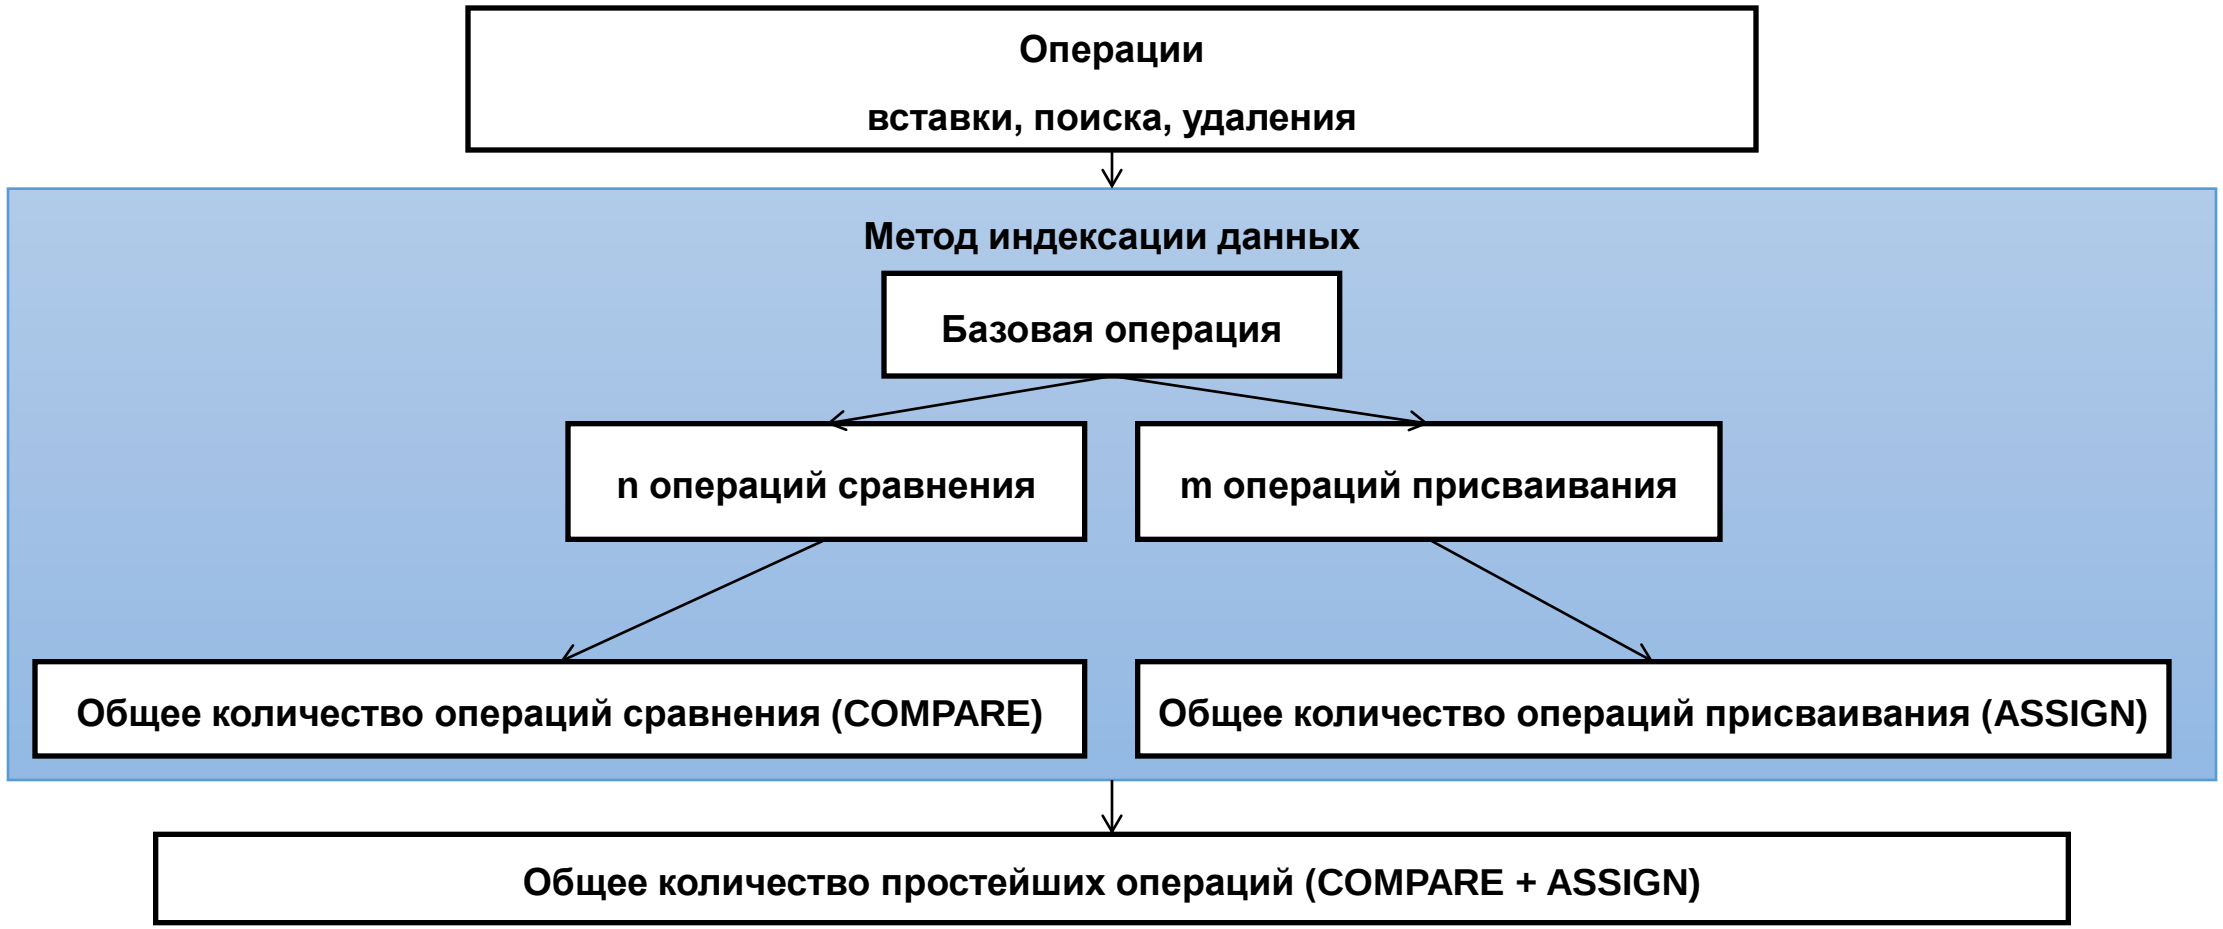

Общая схема работы программы

1. Берется фиксированное число, равное сумме операций.
2. На основе этого числа строится плоскость, в которой при отсечении положительными осями координат образуется треугольник.
3. Для каждой точки этого треугольника определяются координаты в трехмерном пространстве IRS.

Общая схема работы программы

4. По полученным координатам строится нагрузка, в которой количество каждой базовой операции совпадает с координатой по соответствующей оси.
5. Полученная нагрузка применяется к контейнеру (или контейнерам).
6. На основе полученных значений количества простейших операций определяется цвет пикселя.

Преобразование координат

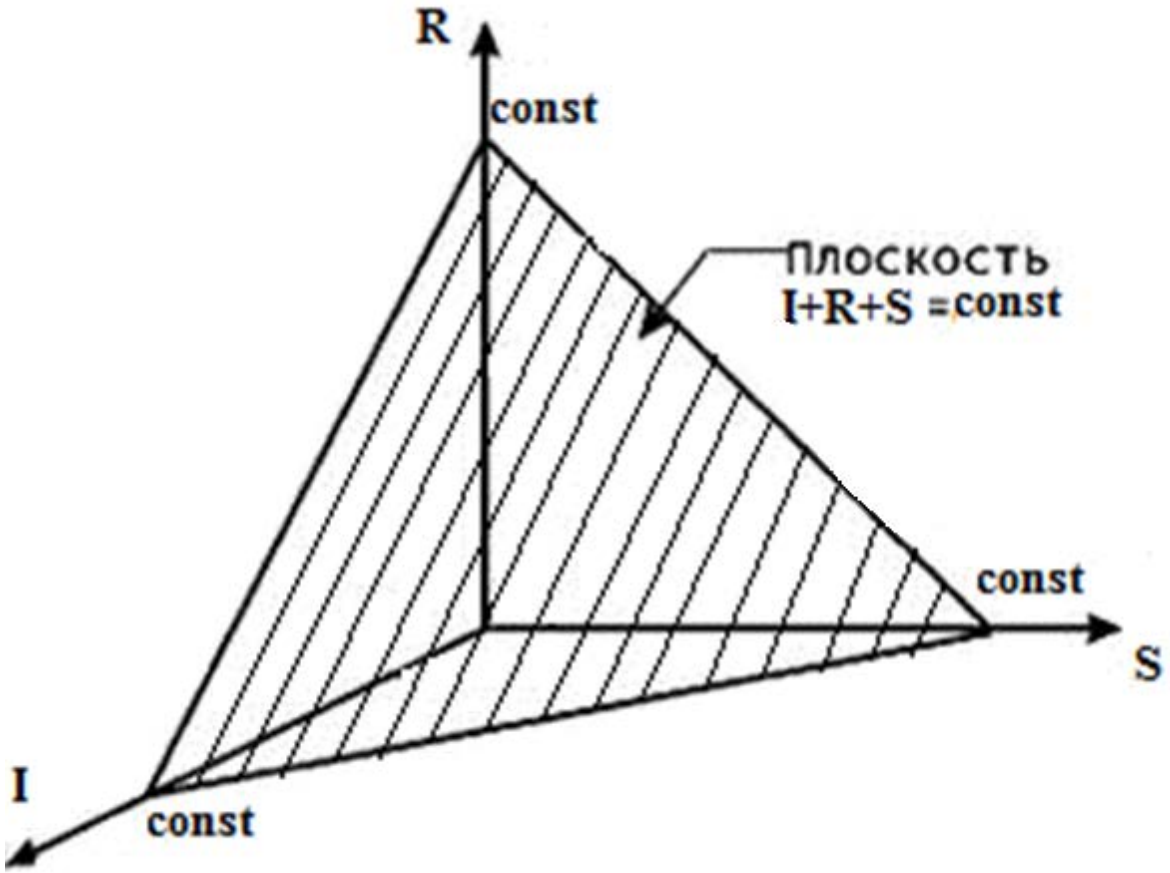

Преобразование координат

Переход от системы экранных координат d=(x, y, z) к системе координат IRS=(insert,remove,select).

Справедливо следующее $X_{IRS} = M \cdot Xd$, где M – матрица перехода.

Окончательно получаем матрицу перехода

$$M = M_{Remove}(35{,}264) * M_{Select}(-45) * T(const * \sqrt{2}/2{,}0{,}0).$$

Определение цвета пикселя для одного контейнера

Для этого используется метод линейного градиента:

- определяется минимальное и максимальное значение среди всех пикселей. Потом получаем коэффициент пикселя из диапазона [0;1] по формуле

$$Ratio = (value - \min) / (\max - \min);$$

- в итоге цвет определяется по формуле:

$$Color = colorMax * ratio + colorMin * (1 - ratio).$$

Определение цвета пикселя для нескольких контейнеров

1. Для каждого контейнера задается свой цвет.
2. Для каждого пикселя ищется минимальное количество операций (по всем тестируемым контейнерам).
3. Выбирается цвет хранилища, соответствующего индексу минимального числа из пункта 2.

Классификация

Признак, по которому можно сказать, что определенная точка в пространстве IRS лучше подходит для одного контейнера, чем для другого.

Простейшим примером классификатора является прямая, по одну сторону от которой оптимальным будет являться один контейнер, а по другую – второй.

Метод опорных векторов (SVM) с линейным ядром.

Классификация

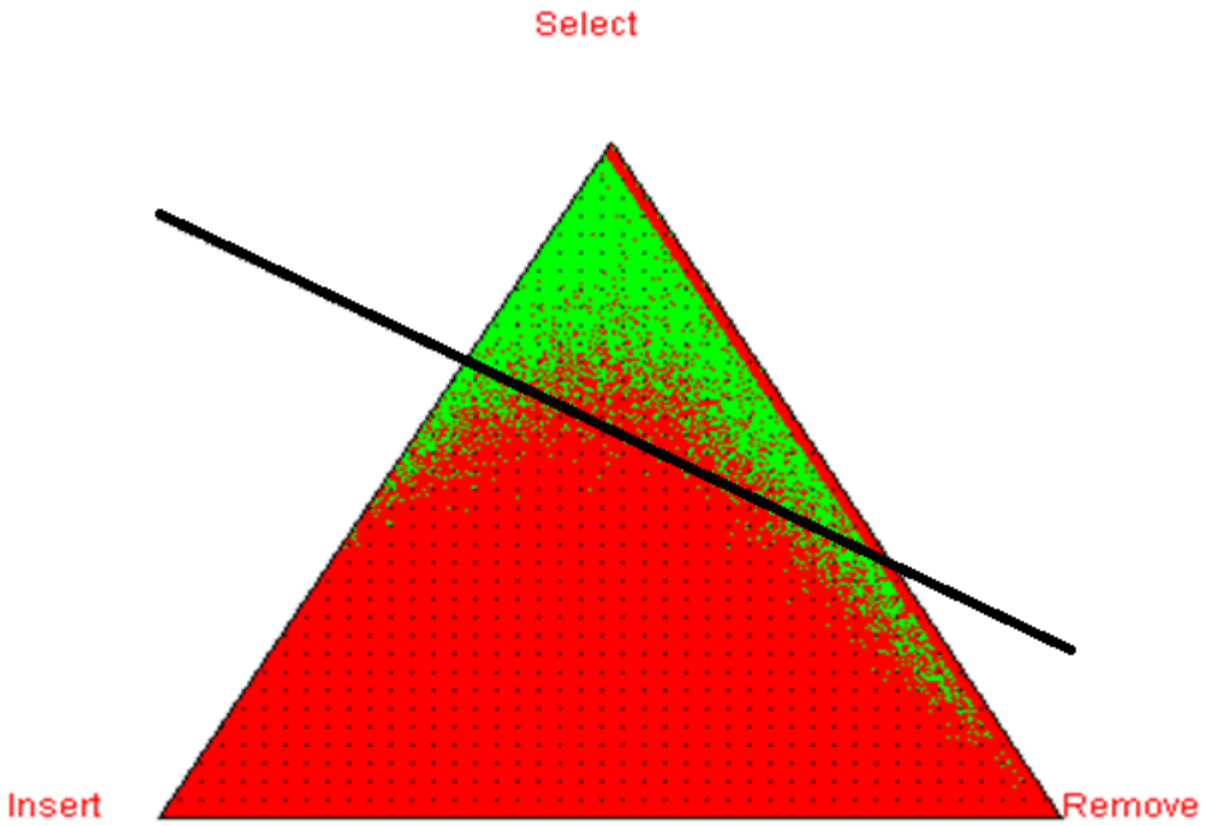

Средства реализации

1. Среда разработки Eclipse Luna Service Release 2 (4.4.2).
2. Язык программирования Java 8.
3. Библиотека для работы с xml-файлами jdom2.
4. Библиотека логирования log4j.
5. Библиотека для решения задачи SVM libsvm.

Требования к аппаратному и программному обеспечению

1. Процессор не ниже Pentium IV 2.6 GHz.
2. Оперативная память размером не менее 1024 Мб.
3. Не менее 1 Гб свободного дискового пространства.
4. Операционная система Windows XP и выше.
5. Виртуальная машина Java версии 1.8.

Интерфейс пользователя

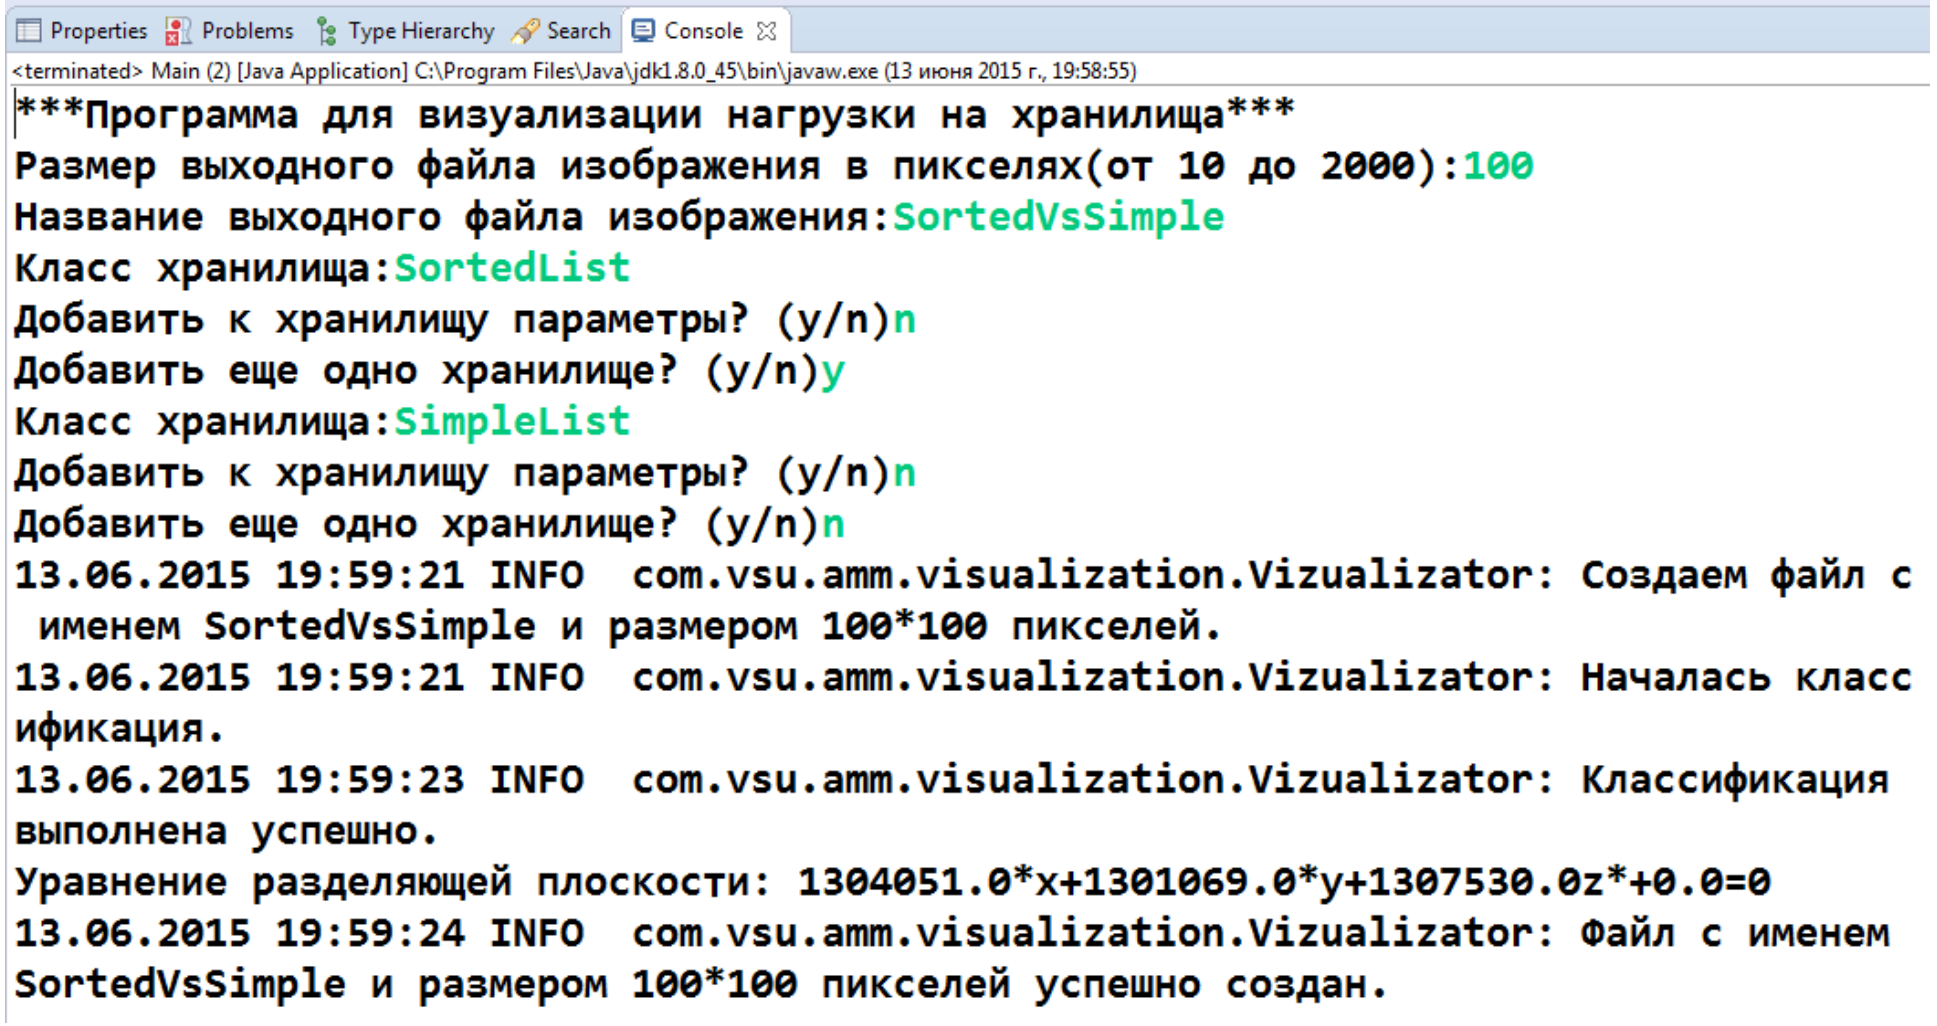

Результат работы программы

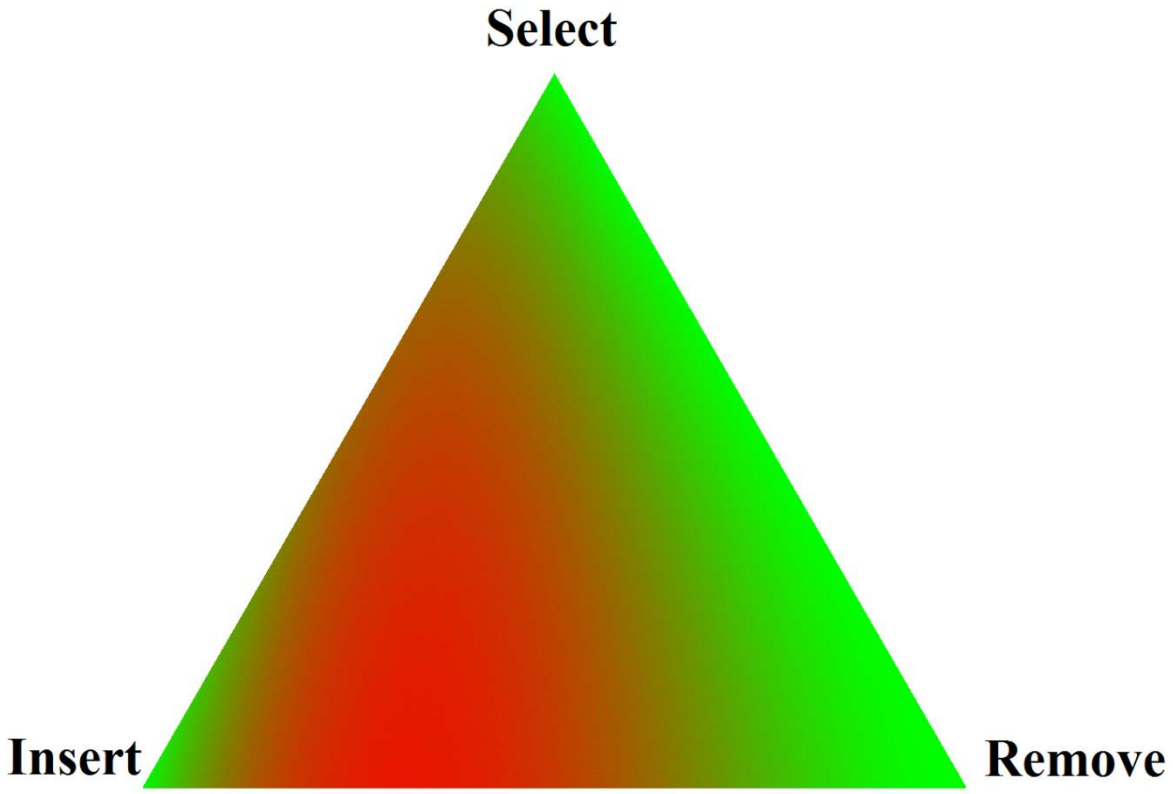

Общая схема работы программы

Общая архитектура программы

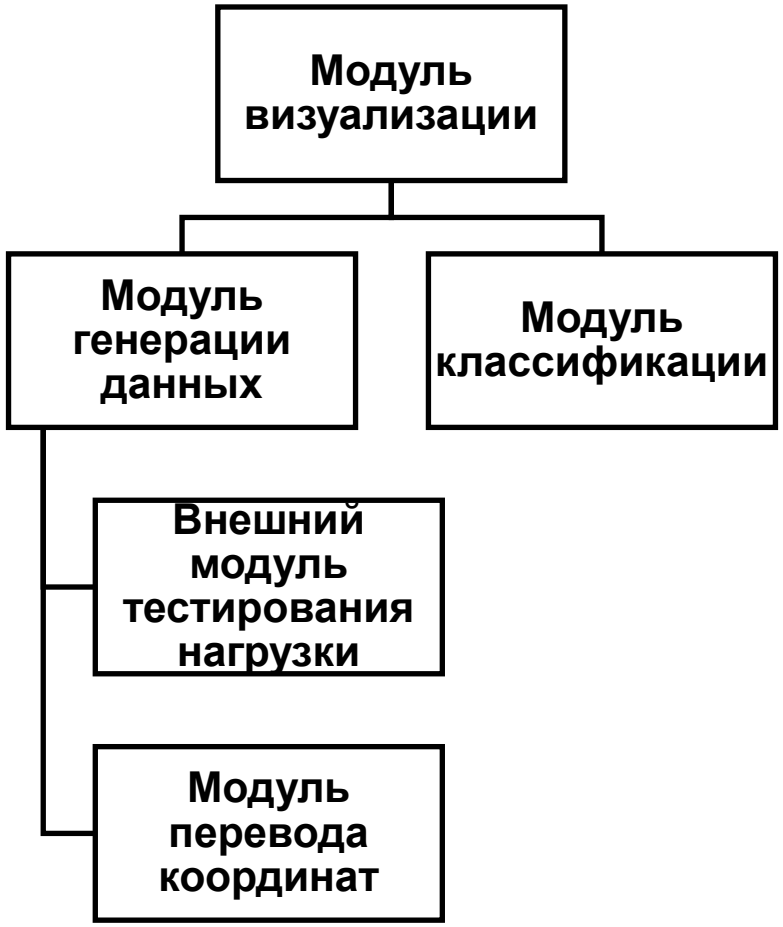

Тестирование простого списка

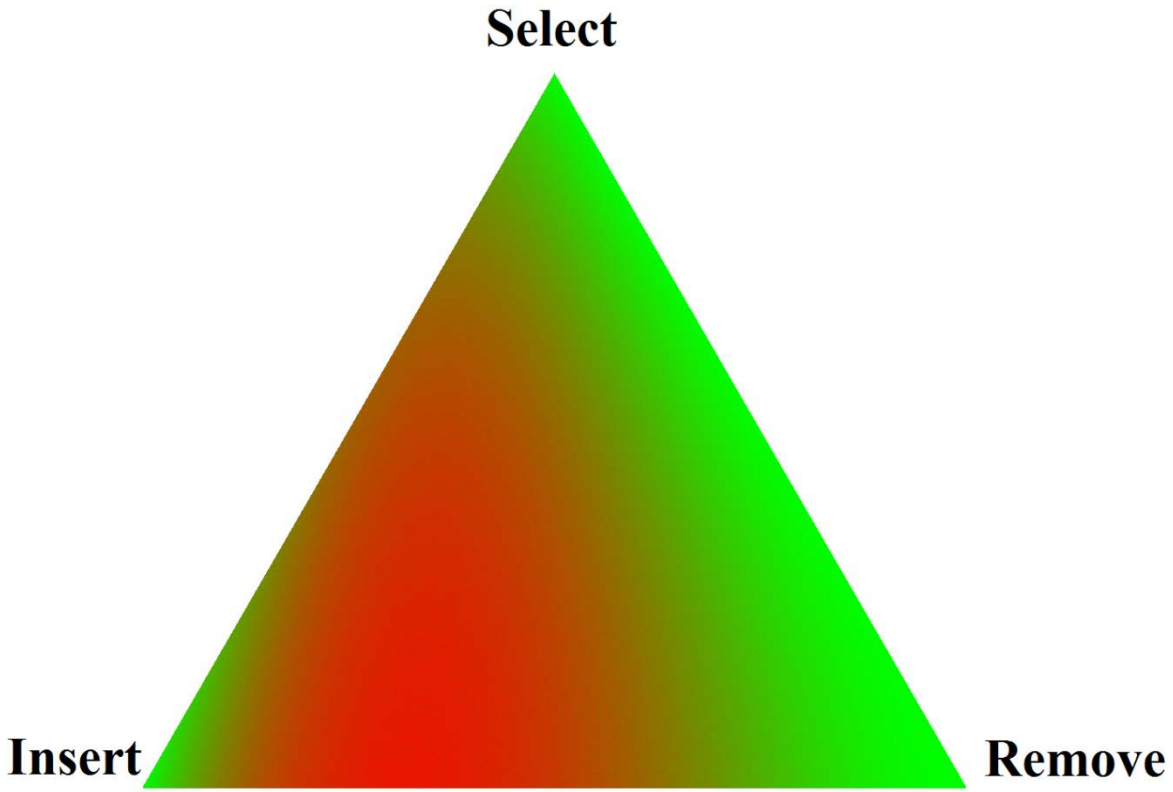

Тестирование сортированного списка

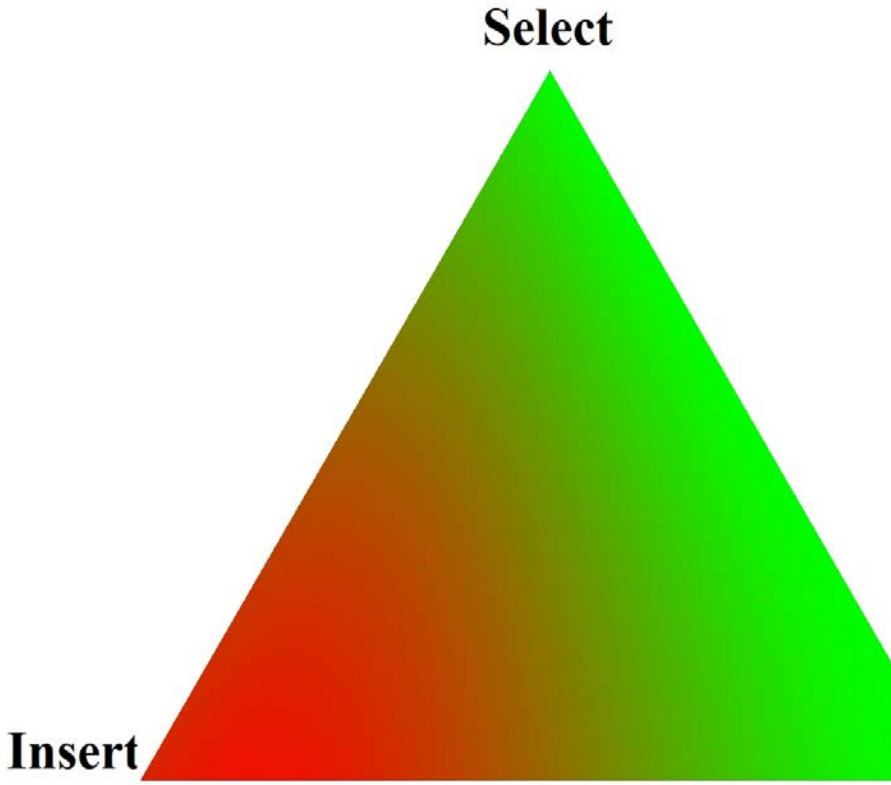

Тестирование B-дерева

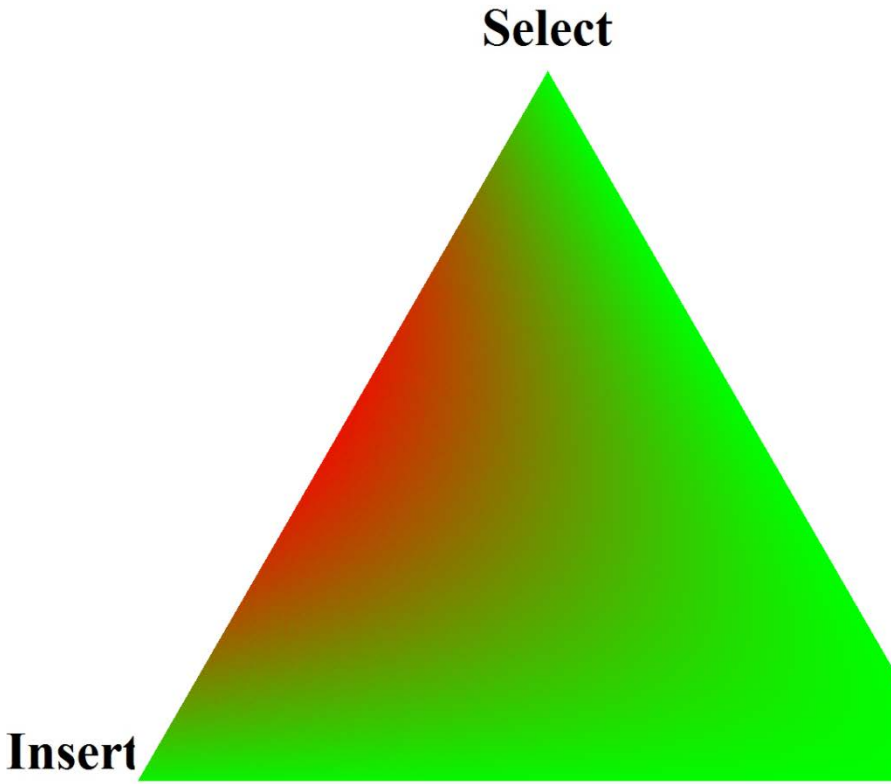

Тестирование простого массива и B-дерева

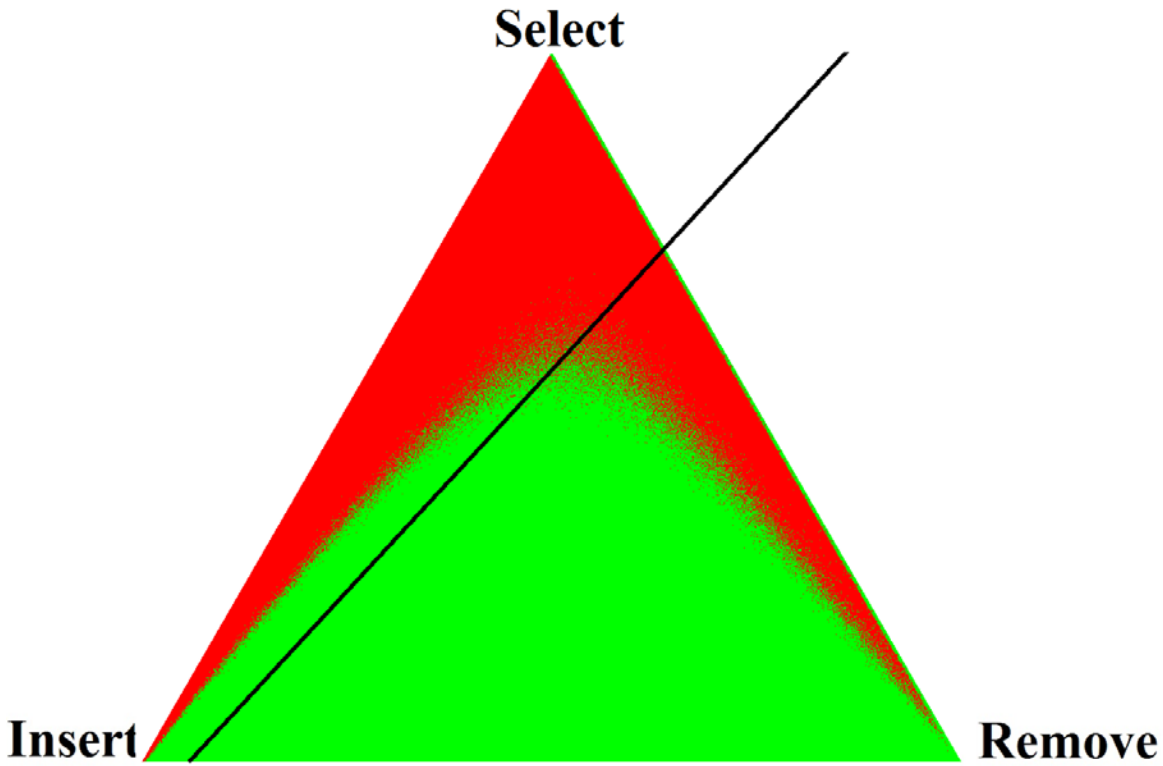

Результаты работы

Разработано программное обеспечение, в котором реализованы:

1. Визуализация нагрузки на одном контейнере.
2. Визуализация сравнения нескольких контейнеров.
3. Алгоритм получения линейного классификатора для адаптивного выбора оптимального способа хранения данных в зависимости от нагрузки.